

Agente de Damas mediante Aprendizaje por Refuerzo Profundo (DQN) con Auto-Juego, comparado contra Minimax con Poda Alfa-Beta

Proyecto Final de Inteligencia Artificial

Integrantes

Aaron Davila Santos

Walter Poma Navarro

Max Jairo Serrano Arostegui

Dery Abraham Gonzales Cruz

29 de junio de 2026

Resumen

Este trabajo presenta la implementación de un entorno de Damas de 8×8 , un agente basado en Deep Q-Network (DQN) entrenable mediante auto-juego y un agente Minimax con poda alfa-beta como línea base. El sistema incluye motor de reglas, codificación de estados, máscara de acciones legales, buffer de experiencia, red objetivo y un orquestador de torneos con alternancia de colores. Sobre el DQN base se aplicaron mejoras de estabilización: recompensa densa por captura y coronación, Double DQN, currículum contra Minimax y actualización suave de la red objetivo. El DQN resultante, entrenado con 4 000 episodios de auto-juego ($\approx 6.5 \times 10^4$ pasos de aprendizaje), alcanza el 3.^{er} lugar en la clasificación ELO (1518.4), por encima de Minimax a profundidades 3 y 4. Una evaluación estocástica adicional confirma que el agente vence con holgura a Minimax de baja profundidad ($d=3$ y $d=4$) pero encuentra un *techo estructural* frente a búsquedas profundas ($d \geq 5$), coherente con el hecho de que el DQN decide sin búsqueda hacia adelante. Todos los experimentos son reproducibles mediante los scripts y notebooks del repositorio.

1. Resumen ejecutivo

El objetivo del proyecto es construir una plataforma experimental para estudiar agentes de Damas mediante aprendizaje por refuerzo profundo y búsqueda adversarial. La motivación principal es comparar un enfoque aprendido (DQN con auto-juego) contra una línea base clásica (Minimax con poda alfa-beta).

El repositorio contiene cuatro componentes principales: un motor de Damas sobre 32 casillas jugables, un entorno compatible con el flujo de aprendizaje por refuerzo, un agente DQN y un agente Minimax. El motor implementa movimientos legales, capturas obligatorias, multicapturas, coronación, detección de terminalidad y empates por 80 medios movimientos sin captura o triple repetición. El agente DQN estima valores $Q(s, a)$ mediante auto-juego, mientras que Minimax explora el árbol de juego hasta una profundidad acotada evaluando hojas con una heurística material; este segundo agente no requiere entrenamiento ya que su fuerza proviene exclusivamente de la búsqueda y de la heurística codificada manualmente.

Tras un DQN base que no superaba a Minimax, se incorporaron mejoras de estabilización (recompensa densa, Double DQN, currículum contra Minimax y actualización suave de la red objetivo) y se entrenó

un agente durante 4000 episodios de auto-juego ($\approx 6.5 \times 10^4$ pasos de aprendizaje). Se realizaron cuatro experimentos reproducibles: análisis de la curva de aprendizaje, barrido de hiperparámetros, evaluación preliminar contra Minimax($d=3$) y torneo round-robin con clasificación ELO entre el DQN y cuatro variantes de Minimax a profundidades 3–6. El agente resultante alcanza el 3.^{er} lugar del torneo (ELO 1518.4), no pierde ninguna partida contra Minimax($d=3$) y ($d=4$) en la evaluación, y una evaluación estocástica confirma su competitividad contra baja profundidad y un techo estructural frente a búsquedas profundas. La batería de pruebas automatizadas reportó 151 pruebas aprobadas.

2. Estado del arte y antecedentes

Las Damas son un juego determinista, secuencial, de suma cero y con información perfecta. Estas propiedades permiten aplicar técnicas clásicas de búsqueda, como Minimax [2], y también métodos de aprendizaje por refuerzo que aprenden políticas o funciones de valor a partir de interacción con el entorno [5]. Samuel [3] demostró ya en 1959 que es posible que un programa aprenda a jugar Damas mejor que su propio creador mediante autoaprendizaje, sentando las bases del aprendizaje por refuerzo aplicado a juegos de tablero.

Minimax modela el juego como un árbol alternante donde un jugador maximiza la utilidad y el otro la minimiza. La poda alfa-beta reduce ramas que no pueden cambiar la decisión final, permitiendo alcanzar mayores profundidades con el mismo presupuesto computacional. Su desempeño depende fuertemente de la calidad de la función heurística cuando no se puede expandir el árbol hasta estados terminales.

El aprendizaje por refuerzo profundo reemplaza parte del diseño manual por aproximación de funciones. En particular, DQN [4] aprende una función $Q(s, a)$ con redes neuronales, replay buffer y red objetivo, estabilizando el aprendizaje frente a la correlación temporal de las transiciones. El principio de optimalidad de Bellman [1] garantiza que, en el límite, la función Q óptima satisface la ecuación de recurrencia que DQN aproxima. En juegos de dos jugadores de suma cero, el entrenamiento por auto-juego resulta atractivo porque el agente genera sus propios datos y puede mejorar enfrentándose contra versiones de su propia política.

3. Dataset y preprocesamiento

No se empleó un dataset externo. Las transiciones del DQN se generan en línea mediante auto-juego: ambos bandos usan la misma red y el mismo agente explora con política ϵ -greedy. Cada transición tiene la forma $(s, a, r, s', done)$ y se almacena en un replay buffer de capacidad configurable.

El estado del tablero se codifica como un vector de 160 valores reales. La representación usa cinco canales sobre las 32 casillas jugables:

- piezas rojas normales;
- damas rojas;
- piezas negras normales;
- damas negras;
- turno actual, codificado como 1 o -1 .

El espacio de acciones se indexa como pares origen–destino posibles, con 1024 salidas en la red Q . Durante la selección de acción se aplica una máscara de legalidad, de modo que los movimientos

ilegales reciben valor $-\infty$ antes de ejecutar el *argmax*. Esta decisión evita que la red escoja acciones inválidas aunque su capa de salida sea fija.

4. Modelo o algoritmo implementado

4.1. Motor de juego

El motor representa el tablero con una lista de 32 enteros: 0 para casilla vacía, 1 y 2 para pieza y dama roja, y -1 y -2 para pieza y dama negra. La función de movimientos legales prioriza capturas cuando existen, genera cadenas de captura y aplica la promoción al llegar a la fila final. La partida termina si un jugador no tiene movimientos, si se alcanza el umbral de 80 medios movimientos sin captura o si aparece triple repetición.

4.2. Agente Minimax

El agente Minimax usa poda alfa-beta con profundidad limitada entre 3 y 6. No requiere entrenamiento: su comportamiento queda completamente determinado por la profundidad de búsqueda y la función heurística que evalúa posiciones no terminales. Dicha heurística considera el material (número y tipo de piezas), la movilidad y la posición relativa de cada bando. El jugador rojo se modela como maximizador y el negro como minimizador; aumentar la profundidad amplía el horizonte de planificación del agente a cambio de mayor costo computacional.

4.3. Agente DQN

El agente DQN aproxima la función de valor de acción $Q(s, a)$ mediante una red completamente conectada (MLP). La entrada es el vector de 160 dimensiones descrito en la Sección 3; le siguen dos capas ocultas de 512 unidades con activación ReLU y una capa de salida de 1024 valores, uno por cada acción indexada del espacio origen-destino. La Figura 1 resume la topología.




Figura 1: Arquitectura de la red Q : MLP $160 \rightarrow 512 \rightarrow 512 \rightarrow 1024$ con activaciones ReLU, seguida del enmascarado de acciones ilegales antes del *argmax*.

La topología es configurable: el número y ancho de las capas ocultas se parametrizan, lo que habilita la comparación arquitectónica de la Sección 5. Durante la inferencia se aplica una máscara de legalidad sobre la salida, asignando $-\infty$ a las acciones ilegales antes del *argmax*; así la política nunca elige un movimiento inválido pese a tener una capa de salida de tamaño fijo. La política de comportamiento es ϵ -greedy con decaimiento lineal de $\epsilon = 1.0$ a $\epsilon = 0.05$, y el objetivo de aprendizaje adopta una formulación *negamax* que se detalla en la Sección 5.

4.4. Justificación de la elección

La comparación central del proyecto enfrenta dos paradigmas. Minimax con poda alfa-beta es búsqueda exacta y no requiere entrenamiento: dada una heurística, garantiza la mejor jugada hasta la profundidad explorada, pero su costo crece exponencialmente con la profundidad y su techo de juego

queda limitado por la calidad de la heurística manual. El DQN, en cambio, aprende una función de valor a partir de la experiencia de auto-juego, sin heurística explícita, a cambio de un entrenamiento costoso y de la inestabilidad propia de la aproximación de funciones.

Se eligió DQN frente a alternativas más sofisticadas como AlphaZero por viabilidad dentro del alcance del curso. AlphaZero combina una búsqueda Monte Carlo (MCTS) guiada por una red de política y valor, lo que exige un presupuesto de cómputo (auto-juego masivo en GPU/TPU) y una complejidad de implementación muy superiores. El DQN conserva la idea de aprender por auto-juego una estimación de valor, pero con una sola red y sin MCTS, lo que lo vuelve entrenable en CPU y suficiente para contrastar de forma controlada el enfoque aprendido contra la línea base de búsqueda clásica. Minimax cumple además el papel de oponente de referencia exigente y reproducible para medir el progreso del DQN.

5. Entrenamiento y validación

5.1. Proceso de entrenamiento

El agente se entrena por auto-juego: ambos bandos comparten la misma red y exploran con política ϵ -greedy. Cada episodio genera una secuencia de transiciones $(s, a, r, s', done)$ hasta alcanzar un estado terminal o el límite de pasos. La recompensa se asigna desde la perspectiva del jugador en turno (+1 si gana, -1 si pierde, 0 en jugadas intermedias y empates) y cada transición se almacena en el replay buffer. Cada `learn_every` transiciones se ejecuta un paso de optimización sobre un minibatch muestreado uniformemente del buffer, y la red objetivo se sincroniza por copia dura cada `target_update_freq` pasos de aprendizaje. El parámetro ϵ decae linealmente con los pasos de aprendizaje.

5.2. Función de pérdida

El DQN minimiza el error de Bellman [1]. Como las Damas son un juego de suma cero por turnos, el valor del estado siguiente se ve desde la perspectiva del oponente, por lo que el objetivo adopta una forma *negamax*:

$$y = \begin{cases} r & \text{si } s' \text{ es terminal,} \\ r - \gamma \max_{a' \in \mathcal{A}_{\text{legal}}(s')} Q_{\theta^-}(s', a') & \text{en otro caso,} \end{cases}$$

donde θ^- son los pesos de la red objetivo y $\mathcal{A}_{\text{legal}}(s')$ el conjunto de acciones legales en s' (las ilegales se enmascaran con $-\infty$ antes del máximo). El signo negativo refleja que el siguiente turno pertenece al oponente: el máximo Q desde s' representa el mejor resultado para el rival, que es el peor para el jugador actual. La pérdida es la función de Huber (`smooth_l1_loss`) entre la predicción $Q_{\theta}(s, a)$ y el objetivo y , más robusta a valores atípicos que el error cuadrático [4], y se optimiza con Adam. La Tabla 1 resume la configuración base.

Cuadro 1: Configuración principal implementada para DQN.

Componente	Valor
Entrada de red	160 valores
Salida de red	1024 acciones indexadas
Capas ocultas	2 capas de 512 unidades
Activación	ReLU
Optimizador	Adam
Pérdida	Huber / <code>smooth_l1_loss</code>
Batch por defecto	64
Replay buffer	50 000 transiciones
Factor de descuento	0.99
Política	ϵ -greedy
Decaimiento ϵ	lineal $1.0 \rightarrow 0.05$
Red objetivo	copia dura periódica

5.3. Ajuste de hiperparámetros y comparación arquitectónica

Se realizó un barrido de un factor a la vez partiendo de la configuración base, midiendo en cada caso la tasa de victoria de la política *greedy* resultante frente a un agente aleatorio tras un número fijo de pasos de aprendizaje. La Tabla 2 recoge el barrido de hiperparámetros y la Tabla 3 la comparación de arquitecturas; la Figura 2 presenta ambas comparaciones de forma visual.

Cuadro 2: Barrido de hiperparámetros (un factor a la vez). Tasa de victoria de la política *greedy* frente a un agente aleatorio.

Configuración	lr	γ	buffer	div. obj.	Tasa
base	10^{-3}	0.99	5 000	10	0.40
lr = 5×10^{-4}	5×10^{-4}	0.99	5 000	10	0.20
lr = 10^{-4}	10^{-4}	0.99	5 000	10	0.15
$\gamma = 0.95$	10^{-3}	0.95	5 000	10	0.45
$\gamma = 0.90$	10^{-3}	0.90	5 000	10	0.50
buffer = 20k	10^{-3}	0.99	20 000	10	0.40
objetivo rápido	10^{-3}	0.99	5 000	40	0.45
objetivo lento	10^{-3}	0.99	5 000	4	0.30

Cuadro 3: Comparación arquitectónica (hiperparámetros base). Tasa de victoria frente a un agente aleatorio.

Arquitectura (capas ocultas)	Tasa
256×256	0.25
512×512	0.60
$512 \times 512 \times 1024$	0.65




Figura 2: Win-rate contra agente aleatorio para cada configuración evaluada. Izquierda: barrido de hiperparámetros. Derecha: comparación de arquitecturas.

La tasa de victoria frente a un agente aleatorio es un *proxy ruidoso* (pocas partidas, alta varianza), por lo que diferencias pequeñas no son significativas. La señal más clara proviene de la comparación arquitectónica: a mayor capacidad, mayor tasa de victoria ($0.25 \rightarrow 0.60 \rightarrow 0.65$). Entre los hiperparámetros, reducir el factor de descuento ($\gamma = 0.90-0.95$) y ampliar el buffer no degradaron el desempeño, mientras que tasas de aprendizaje muy bajas ($lr = 10^{-4}$) lo empeoraron notablemente.

5.4. Mejoras de estabilización

El DQN base entrenado solo por auto-juego con recompensa dispersa no superaba a Minimax, y su rendimiento contra el rival oscilaba a lo largo del entrenamiento (mejoraba y luego se degradaba). Para estabilizarlo se incorporaron cuatro mejoras, todas dentro del paradigma DQN: (i) *modelado de recompensas* (*reward shaping*) denso, que premia capturas y coronaciones desde la perspectiva del jugador en turno para densificar la señal de aprendizaje; (ii) *Double DQN*, que desacopla la selección de la acción (red *online*) de su evaluación (red objetivo) para reducir la sobreestimación de los valores [6]; (iii) *currículum* contra Minimax: una fracción de los episodios se juega contra el agente de búsqueda y se almacenan todas las transiciones, aportando un ancla externa y demostraciones expertas al *buffer* (válido por ser DQN off-policy); y (iv) *actualización suave* (Polyak) de la red objetivo en lugar de copia dura [7]. Como el entrenamiento por auto-juego sigue siendo oscilatorio, se emplea además promediado de pesos (*Stochastic Weight Averaging*) [8] de los mejores *checkpoints* para obtener un modelo más estable que cualquiera individual.

5.5. Curvas de aprendizaje

La Figura 3 muestra la evolución de la pérdida Huber suavizada y el decaimiento de ϵ junto con la tasa de victoria en auto-juego durante el entrenamiento.




Figura 3: Curvas de entrenamiento del DQN por auto-juego: pérdida Huber suavizada (izquierda) y decaimiento de ϵ junto con la tasa de victoria en auto-juego (derecha).

La pérdida Huber descende y se estabiliza conforme avanza el entrenamiento. Sin embargo, es preciso interpretar esta métrica con cautela: una pérdida baja indica que la red ajusta bien su objetivo de Bellman *sobre los datos de auto-juego*, pero no se traduce directamente en mayor fuerza frente a Minimax. De hecho, al evaluar checkpoints intermedios contra el rival se observa un comportamiento *oscilatorio* (el rendimiento sube y baja), síntoma de la inestabilidad propia del auto-juego puro. Por ello el mejor modelo no es necesariamente el último *checkpoint*, y resulta clave la selección/promediado de los mejores (Sección de mejoras de estabilización). La tasa de victoria en auto-juego ronda el 50 % por construcción —ambos bandos comparten la red—, por lo que es poco informativo como medida de fuerza; la medida válida es la evaluación contra Minimax (Sección 6).

5.6. Validación

La validación técnica se apoya en una batería de 151 pruebas automatizadas (**pytest**) que cubren el motor, el entorno, la heurística, el Minimax, el torneo, el ajuste de hiperparámetros, las mejoras del DQN (modelado de recompensas, Double DQN, actualización suave, promediado de pesos) y la evaluación; todas pasan. A nivel de modelo, se entrenó por auto-juego un checkpoint DQN de 4000 episodios ($\approx 6.5 \times 10^4$ pasos de aprendizaje) que se incorporó al torneo final de la Sección 6.

Un punto metodológico importante es *cómo* se mide la fuerza del DQN. La evaluación *greedy* estándar es engañosa: como el DQN *greedy* y Minimax son ambos deterministas, todas las partidas desde el estado inicial son idénticas y solo varían por el color, por lo que el torneo aporta esencialmente dos muestras por confrontación. Para obtener una medida estadísticamente significativa se añadió una *evaluación estocástica* en la que el DQN juega con un ϵ pequeño que introduce variedad, sobre 30 partidas con semillas pareadas. Además, se distingue el oponente de *entrenamiento* (Minimax usado en el currículum) del oponente *no visto* (*held-out*: una profundidad no usada en el currículum), para medir generalización real y no sobreajuste al rival de práctica. Esta evaluación estocástica confirma que el DQN vence con holgura a Minimax de baja profundidad y, mediante promediado de pesos (SWA) de los mejores *checkpoints*, un único modelo alcanza del orden de 80 % de victorias contra Minimax($d=3$) y 60 % contra Minimax($d=4$).

La Tabla 4 resume la *progresión* de las mejoras, manteniendo la trazabilidad del trabajo: cada paso aporta sobre el anterior, y el promediado de pesos (SWA) es la mejora final que consolida un único modelo fuerte tanto contra ($d=3$) como contra ($d=4$).

Cuadro 4: Progresión de las mejoras: tasa de victoria del DQN (evaluación estocástica, 30 partidas) contra Minimax. La columna $d=4$ es *de reserva* (no usada en el currículum) y, por tanto, la comparación más limpia.

Configuración	vs $d=3$	vs $d=4$
DQN base (recompensa dispersa)	0 %	0 %
+ Fase 1 (modelado de recompensas + Double DQN)	73 %	3 %
+ Fase 2 (currículum + actualización suave)	57 %*	67 %
+ SWA (promediado de checkpoints)	80 %	63 %

* En la Fase 2, Minimax($d=3$) es el oponente de *entrenamiento* (currículum); por eso la métrica fiel de generalización es la columna $d=4$ (no vista en el currículum).

6. Resultados

Esta sección presenta los resultados de la evaluación directa del DQN entrenado frente a las variantes de Minimax. El análisis del proceso de entrenamiento, el barrido de hiperparámetros y la curva de aprendizaje se presentaron en la Sección 5.

6.1. Evaluación preliminar: DQN contra Minimax($d=3$)

Con el checkpoint obtenido tras 4000 episodios se realizó una evaluación de 30 partidas contra Minimax($d=3$), alternando colores en cada partida.

Cuadro 5: Métricas de la evaluación preliminar: DQN(ep64846) vs Minimax($d=3$).

Métrica	Valor
Partidas jugadas	30
Victorias DQN	15 (50 %)
Derrotas DQN	0 (0 %)
Empates	15 (50 %)
Recompensa media	+0.500
Longitud media	91.5 semijugadas
Tiempo por jugada DQN	0.37 ms

Con las mejoras de estabilización, el DQN ya no pierde contra Minimax($d=3$): gana el 50 % de las partidas y empata el resto (recompensa media +0.5, ninguna derrota). Es un salto cualitativo respecto al DQN base, que perdía la totalidad de las partidas. El tiempo por jugada de 0.37 ms confirma además que la inferencia de la red neuronal es mucho más rápida que la evaluación del árbol Minimax.

6.2. Torneo final y clasificación ELO

Se realizó un torneo round-robin entre el DQN y cuatro variantes de Minimax (profundidades 3 a 6), con 20 partidas por confrontación y alternancia de colores. El ELO relativo se calculó con $K = 32$ y valor inicial 1500.

Cuadro 6: Clasificación ELO tras el torneo final. La etiqueta **ep** del DQN indica pasos de aprendizaje (≈ 4000 episodios), no episodios.

Posición	Agente	ELO
1	Minimax(d=6)	1714.4
2	Minimax(d=5)	1628.7
3	DQN(ep64846)	1518.4
4	Minimax(d=4)	1466.5
5	Minimax(d=3)	1172.0




Figura 4: Izquierda: clasificación ELO por agente. Derecha: mapa de calor de la tasa de victoria entre todos los pares de agentes (cada celda muestra la fracción de victorias del agente de la fila sobre el de la columna).




Figura 5: Win-rate del DQN frente a Minimax a profundidades 3, 4, 5 y 6. Izquierda: porcentaje de victorias. Derecha: distribución de resultados por profundidad.

Entre las variantes de Minimax la fuerza crece de forma monótona con la profundidad ($d=6 > d=5 > d=4 > d=3$). El DQN con las mejoras de estabilización se inserta en el **3.º lugar** con un ELO de 1518.4, por encima de Minimax($d=4$) y ($d=3$): un avance notable frente al DQN base, que quedaba último. En el torneo el DQN no pierde contra Minimax($d=3$), ($d=4$) ni ($d=6$) (gana la mitad y empata la otra mitad), y pierde la totalidad contra ($d=5$).

Esta no-monotonía aparente —ganar/empatar a ($d=6$) pero perder a ($d=5$)— es un *artefacto de*

la evaluación determinista: como ambos agentes son deterministas, cada confrontación produce solo dos trayectorias (una por color), de modo que el resultado depende de líneas concretas y no de una superioridad estadística. La evaluación estocástica (Sección 5) corrige este efecto y da la imagen real: el DQN vence con holgura a Minimax de baja profundidad ($d=3$, $d=4$) pero no obtiene victorias contra ($d=5$) ni ($d=6$). Esto evidencia un *techo estructural*: al decidir sin búsqueda hacia adelante, el agente reactivo no alcanza a una búsqueda profunda, por más entrenamiento que reciba.

7. Discusión

Los resultados confirman que la profundidad de búsqueda determina la fuerza de Minimax de forma monótonica: cada nivel adicional mejora el ELO en aproximadamente 90–180 puntos. Este comportamiento es coherente con la teoría, ya que una mayor profundidad permite al agente anticipar consecuencias más lejanas dentro del mismo árbol de búsqueda con la misma heurística material–posicional–movilidad.

El resultado más relevante es que el DQN, tras las mejoras de estabilización, pasa de perder todas sus partidas a ser *competitivo contra Minimax de baja profundidad*: no pierde contra ($d=3$) ni ($d=4$) y se sitúa tercero en la clasificación ELO. La pieza decisiva fue el currículum contra Minimax: entrenar contra un oponente fijo y fuerte (ancla externa), almacenando sus jugadas como demostraciones expertas, rompió el colapso de distribución del auto-juego puro y permitió generalizar. La métrica con el oponente no visto (una profundidad no usada en el currículum) confirmó que la mejora es real y no un sobreajuste al rival de práctica.

El mapa de calor de la tasa de victoria (Figura 4) muestra además que la relación de dominancia entre los Minimax no es transitiva de forma perfecta: Minimax($d=3$) obtiene 50 % contra Minimax($d=6$), lo que se explica por la alternancia de colores y la repetición determinista de trayectorias. Dos agentes deterministas que parten del mismo estado inicial y alternan colores producen exactamente dos trayectorias distintas, por lo que el 50 % puede reflejar que uno gana siempre con rojas y el otro con negras.

Respecto a la dinámica de entrenamiento, encontramos que *aumentar la cantidad de episodios no es el factor determinante*: el rendimiento contra Minimax oscila a lo largo del entrenamiento y extender la corrida no lo mejora de forma estable (incluso puede degradarlo). La causa es la inestabilidad del auto-juego puro: objetivo móvil, olvido catastrófico por un buffer finito y colapso de la distribución de estados. Lo que sí ayuda es estabilizar (currículum, actualización suave de la red objetivo, buffer amplio) y, sobre todo, *seleccionar o promediar los mejores checkpoints* mediante SWA, ya que el último checkpoint rara vez es el mejor. Cruzar el techo estructural frente a búsquedas profundas ($d \geq 5$) requeriría incorporar búsqueda en el momento de decidir (p. ej. MCTS, al estilo de AlphaZero [9]), lo que excede el alcance de este trabajo.

8. Conclusiones

Se completó una plataforma funcional y evaluada para experimentar con agentes de Damas. El motor implementa las reglas del juego, el entorno expone observaciones y acciones aptas para aprendizaje por refuerzo, el agente Minimax ofrece una línea base clásica determinista y el agente DQN contiene los componentes esenciales de aprendizaje profundo por auto-juego.

Los experimentos confirman tres resultados principales. Primero, la infraestructura de evaluación es correcta: el módulo de torneo captura diferencias de fuerza entre agentes y la clasificación ELO refleja el orden esperado por profundidad de búsqueda. Segundo, con mejoras de estabilización (recompensa densa, Double DQN, currículum contra Minimax, actualización suave de la red objetivo y promediado

de pesos) el DQN se vuelve competitivo contra Minimax de baja profundidad: alcanza el 3.^{er} lugar en la clasificación ELO y no pierde contra ($d=3$) ni ($d=4$); no obstante, persiste un techo estructural frente a búsquedas profundas ($d \geq 5$) por la ausencia de búsqueda en el momento de decidir. Tercero, el barrido de hiperparámetros muestra que las tasas de aprendizaje bajas degradan el rendimiento y que la arquitectura 512×512 ofrece la mejor relación capacidad–costo evaluada en este estudio.

El trabajo futuro se orienta a consolidar la reproducibilidad del entorno para la entrega final y, dada la evidencia de un techo estructural, a evaluar la incorporación de búsqueda en el momento de decidir —por ejemplo, Monte Carlo Tree Search al estilo de AlphaZero [9]— para superar las limitaciones de un agente puramente reactivo frente a búsquedas profundas. Asimismo, se plantea repetir los experimentos con varias semillas para acotar la varianza de las métricas. Los notebooks reproducibles del repositorio permiten regenerar todas las figuras automáticamente.

9. Bibliografía

Referencias

- [1] R. Bellman. *Dynamic Programming*. Princeton University Press, 1957.
- [2] C. E. Shannon. Programming a computer for playing chess. *Philosophical Magazine*, 41(314):256–275, 1950.
- [3] A. L. Samuel. Some studies in machine learning using the game of checkers. *IBM Journal of Research and Development*, 3(3):210–229, 1959.
- [4] V. Mnih et al. Human-level control through deep reinforcement learning. *Nature*, 518:529–533, 2015.
- [5] R. S. Sutton and A. G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2nd edition, 2018.
- [6] H. van Hasselt, A. Guez, and D. Silver. Deep reinforcement learning with double Q-learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 30(1), 2016.
- [7] T. P. Lillicrap et al. Continuous control with deep reinforcement learning. *International Conference on Learning Representations (ICLR)*, 2016.
- [8] P. Izmailov, D. Podoprikin, T. Garipov, D. Vetrov, and A. G. Wilson. Averaging weights leads to wider optima and better generalization. *Conference on Uncertainty in Artificial Intelligence (UAI)*, 2018.
- [9] D. Silver et al. A general reinforcement learning algorithm that masters chess, shogi, and Go through self-play. *Science*, 362(6419):1140–1144, 2018.